Создано 01 апр, 00:17, обновлено 14 апр, 19:53

КОД - Грязные Данные

ГИПЕР ВАЖНАЯ ИНФА!!! МНОГО МАТЕМАТИКИИИ

Обработка грязных данных

Перед выполнением поиска исходный каталог проходит этап очистки и гармонизации.
Это необходимо, потому что в реальных записях часто встречаются пропуски, ошибки формата, перепутанные границы диапазонов и физически невозможные значения.
Если такие записи не исправить заранее, то даже хороший алгоритм поиска будет давать неточные или неполные результаты.

1. Исправление форматных ошибок

К форматным ошибкам относятся:

- пробелы внутри чисел, например `1 000` вместо `1000`;
- неправильные десятичные разделители, например `1,5` вместо `1.5`;
- смешение единиц измерения;
- пустые или нестандартные обозначения пропусков, например `–`, `нет данных`, `NULL`.

Такие ошибки исправляются на этапе парсинга.
Алгоритм выполняет удаление пробелов, нормализацию разделителей и приведение значений к единому формату.
Если поле не удаётся преобразовать в число, оно помечается как пропущенное и передаётся на следующий этап обработки.

2. Исправление диапазонов

Во многих каталогах числовые параметры задаются интервалами, например:

- производительность: `900–2520`;
- давление: `52–22`;
- мощность: `0.5–500`.

Если границы записаны в обратном порядке, то выполняется простое исправление:

если min > max, то поменять min и max местами

Это относится к самым простым и безопасным исправлениям, потому что не меняет смысл данных, а только приводит их к корректной записи.

3. Обнаружение выбросов

Чтобы найти подозрительные значения, используется Z-score.
Он показывает, насколько далеко значение отклоняется от среднего по сравнению со стандартным отклонением:

$$Z = \frac{x - \mu}{\sigma}$$

где:

- x — текущее значение;
- μ — среднее значение по выборке;
- σ — стандартное отклонение.

Если: |**Z**|**>3** то значение считается аномальным.

Для более устойчивой проверки можно использовать модифицированный Z-score на основе медианы и MAD:

Статус	В работе
Тип	Задача
Приоритет	Критичный
Дата начала	01 апр
Дедлайн	18 апр
Автор	Андреев Алек
Исполнитель	Егор Баранов
Наблюдатели	Андреев Алек Zaman Rzaev Вся Команда Добавить меня
Проект	Веб приложение продаже промышленных вентиляторов
Связанные цели	—
Теги	—
Компоненты	—
Доски	База данных Поиск и функцио (общее) Доска проекта Ве приложение по продаже промышленных вентиляторов Документация

Agile

Изменить список параметров

$$Z_{mod} = \frac{0.6745(x - median)}{MAD}$$

где:

- \(median\) — медиана выборки;
- \(MAD\) — медианное абсолютное отклонение.

Такой вариант удобен, когда в данных есть сильные выбросы и среднее значение становится нестабильным.

4. Физическая верификация

Для вентиляторов можно проверить согласованность параметров через физическую формулу мощности:

$$N_y = \frac{Q \times p}{\eta \times 3600}$$

- *Ny* — мощность;
- (Q) — производительность;
- (p) — давление;
- *η* — коэффициент полезного действия.

Если в записи указана мощность, то можно сравнить её с расчётной. Для этого используется относительное отклонение:

$$\Delta = \frac{|N_y^{\text{заявленная}} - N_y^{\text{расчётная}}|}{N_y^{\text{расчётная}}} \times 100\%$$

Интерпретация может быть такой:

- если Δ<20%Δ<20%, запись считается физически согласованной;
- если 20%≤Δ<100%20%≤Δ<100%, запись считается сомнительной;
- если Δ≥100%Δ≥100%, запись считается критически ошибочной.

5. Восстановление пропущенных значений

Если в записи не хватает одного из параметров, значение восстанавливается по приоритету:

1. если можно использовать физическую формулу, параметр вычисляется из других известных величин;
2. если физический расчёт невозможен, берётся медиана по кластеру;
3. если и это невозможно, используется общее типовое значение по категории.

Например, если известны \(Q\), \(p\) и ηη, то мощность восстанавливается по формуле:

$$N_y = \frac{Q \times p}{\eta \times 3600}$$

Если отсутствует коэффициент полезного действия, то можно взять медиану ηη по той же группе вентиляторов.

6. Индекс достоверности

После всех исправлений каждой записи присваивается индекс достоверности.
Он нужен для того, чтобы пользователь мог понять, насколько записи можно доверять.

Простой вариант расчёта можно записать так:

$$Confidence = 1.0 \times 0.6^V \times 0.9^C \times 0.95^M$$

где:

- \(V\) — число физических нарушений;
- \(C\) — число выполненных корректировок;
- \(M\) — число восстановленных пропусков.

Смысл формулы простой:
чем больше ошибок и исправлений, тем ниже доверие к записи.

Как выглядит алгоритм в целом

1. Считать запись из файла.
2. Исправить форматные ошибки.
3. Привести диапазоны к правильному виду.
4. Проверить выбросы по Z-score.
5. Проверить физическую согласованность по формуле мощности.
6. Восстановить пропущенные значения.
7. Рассчитать индекс достоверности.
8. Сохранить метаданные о всех исправлениях.

$$Z = \frac{x - \mu}{\sigma}$$

image.png
1 апр

$$Z_{mod} = \frac{0.6745(x - median)}{MAD}$$

image.png
1 апр

$$N_y = \frac{Q \times p}{\eta \times 3600}$$

image.png
1 апр

$$\Delta = \frac{|N_y^{\text{паспортная}} - N_y^{\text{расчётная}}|}{N_y^{\text{расчётная}}} \times 100\%$$

image.png
1 апр

$$N_y = \frac{Q \times p}{\eta \times 3600}$$

image.png
1 апр

$$Confidence = 1.0 \times 0.6^V \times 0.9^C \times 0.95^M$$

image.png
1 апр

Прикрепить файлы Связь с задачей Чеклист

Комментарии Вложения История Коммиты

Сначала старые

Начните писать текст или введите "/", чтобы открыть список команд

© 2026 ООО «